

# Lab1

## Lab 描述

HTML 是一种标记语言，用于创建网页。HTML 由一系列标签组成，这些标签定义了网页的结构、内容和外观。HTML 标签通常由尖括号包围，如 `<html>`、`<head>`、`<body>` 等。HTML 标签可以嵌套，这意味着一个标签可以包含其他标签。

下面是使用 html 表示一个简单的网页的例子：

```
<html>
  <head>
    <title>My Webpage</title>
  </head>
  <body>
    <h1 id="page-title">welcome to my webpage</h1>
    <p id="description">This is a paragraph.</p>
    <ul id="list">
      <li id="item1">Item 1</li>
      <li id="item2">Item 2</li>
      <li id="item3">Item 3</li>
    </ul>
    <div id="footer">
      this is a text context in div 元素内部的文本必须是其第一个孩子
      <p id="last-updated">Last updated: 2024-01-01</p>
      <p id="copyright">Copyright © 2021 Mywebpage.com</p>
    </div>
  </body>
</html>
```

本次 Lab 要求开发一个基于命令行的编辑器对 HTML 进行编辑，用以考察对 OO 和设计模式的理解，包括：

## 1. HTML 模型

根据 Lab 的需要，你需要设计一个简化版本的 HTML 的面向对象的模型，从而保存并操作 HTML 内容。

为了简化要求，本次 Lab 中对于 HTML 的约定如下：

1. `<html>`、`<head>`、`<title>`、`<body>` 四个标签有且仅有一个。HTML 文件顶层是 `<html>` 元素，其只有两个子元素，依序为 `<head>` 和 `<body>`。同时，`<title>` 是 `<head>` 的子元素。结构如下：

```
<html>
  <head>
    <title>My Webpage</title>
  </head>
  <body>
    ...
  </body>
</html>
```

2. 元素内部可以包含文本内容，但文本必须处在该元素的其他子元素之前（参见上述例子中的 `<div id="footer">`）。

- 属性只支持 id，除 <html>，<head>，<title>，<body> 外其他元素必须拥有 id 属性，若这四个标签没有提供 id，默认 id 为标签名。同时 id 应该具有唯一性。
- HTML 的解析有一定的工作量，但这部分并不是我们考核的重点。建议查找使用现有的 HTML 解析器，比如 Jsoup(java)等。

## 2. 编辑功能

实现一个基于命令行的 HTML 编辑器，可以实现基本的 HTML 编辑功能，如在某元素之后插入元素、在某元素内部添加子元素、删除元素、修改元素 id、修改元素文本等。同时，编辑器需要支持撤销(Undo)和重做(Redo)功能。

## 3. IO

- 能够读入 HTML 文件，将 HTML 字符串转化为你所设计的 HTML 面向对象模型。
  - 可以手动解析 HTML 字符串（利用栈等数据结构）；也可以使用现有的 HTML 解析器，比如 Jsoup 中构造的模型，来辅助生成你自己设计的模型。
  - 简便起见，可以默认读入的文件是格式良好的 HTML。
- 能够以基于树的格式和基于缩进的格式两种方式显示结果。
  - 树的格式：

```
html
├─ head
│   └─ title
│       └─ My webpage
└─ body
    ├─ h1#page-title
    │   └─ welcome to my webpage
    ├─ p#description
    │   └─ This is a paragraph.
    ├─ ul#list
    │   ├─ li#item1
    │   │   └─ Item 1
    │   ├─ li#item2
    │   │   └─ Item 2
    │   └─ li#item3
    │       └─ Item 3
    └─ div#footer
        ├─ this is a text context in div
        ├─ p#last-updated
        │   └─ Last updated: 2024-01-01
        └─ p#copyright
            └─ Copyright © 2021 Mywebpage.com
```

判断当前是否为父元素的最后一个孩子  
再相应打印：

（父元素要往下走的时候，判断孩子位置（ ）；  
先进入孩子，再判断自己是否是参数父亲的最后一个孩子）

不是最后一个孩子时

- 输出：已有prefix + “ ” + 内容  
- 传递：已有prefix+ “ | ” （给孩子）

是最后一个孩子时

- 输出：已有prefix + “ ” + 内容  
- 传递：已有prefix+ “ ” （给孩子）

- 缩进的格式：

```
<html>
  <head>
    <title>My webpage</title>
  </head>
  <body>
    <h1 id="page-title">welcome to my webpage</h1>
    <p id="description">This is a paragraph.</p>
```

```
<ul id="list">
  <li id="item1">Item 1</li>
  <li id="item2">Item 2</li>
  <li id="item3">Item 3</li>
</ul>
<div id="footer">
  this is a text context in div
  <p id="last-updated">Last updated: 2024-01-01</p>
  <p id="copyright">Copyright © 2021 Mywebpage.com</p>
</div>
</body>
</html>
```

**注意**，Lab2 的部分会要求显示一个其它对象的数据结构，比如当前工作目录的文件夹的树形结构。需要考虑树形结构构造代码的灵活性。

3. 能够将编辑器中的 HTML 模型以 HTML 字符串的形式写入文件保存。

- 需要确保编辑器之后能够再次读取该文件并继续编辑。

## 4. 拼写检查

选择合适的拼写检查服务，实现对元素中的文本内容进行拼写检查，并报告错误。

可以考虑以下拼写检查服务：

API: <https://dev.languagetool.org/public-http-api>

Java: <https://dev.languagetool.org/java-api>

Python: `spell-checker` 库或 `pyspellchecker` 库

## 注意：

架构是 Lab 需要考核的重要内容，

1. 管理各个模块(package)的依赖关系，并画出依赖关系
2. 针对各个模块写代码进行自动化测试。
3. 需要管理对相对不稳定的第三方库的依赖，比如，如果依赖了 Jsoup 作为 HTML 的分析工具，对 Jsoup 的依赖应该限制在特定的范围。

## 命令设计

### 编辑类命令

提示：除 `<html>`，`<head>`，`<title>`，`<body>` 外其他元素必须拥有 id 属性，若这四个标签没有提供 id，默认 id 为标签名。同时 id 应该具有唯一性。

#### 1. insert 在某元素之前插入新元素

```
insert tagName idValue insertLocation [textContent]
```

- tagName 为新元素的元素标签。
- idValue 为新元素的 id，注意 id 不能与其他元素重复。
- insertLocation 为插入位置元素的 id，新元素将插入到该元素之前。 **插到之前**

- `textContent` 为可选参数，表示新元素中的文本内容。

## 2. `append` 在某元素内插入新元素

```
append tagName idValue parentElement [textContent]
```

- `tagName` 为新元素的元素标签。
- `idValue` 为新元素的 `id`，注意 `id` 不能与其他元素重复。
- `parentElement` 为目标父元素的 `id`，新元素将被插入到该元素内部，并且成为该元素的最后一个子元素。
- `textContent` 为可选参数，表示新元素中的文本内容。

插到之后

## 3. `edit-id` 编辑某元素的 `id`

```
edit-id oldId newId
```

- `oldId` 为现有元素的 `id`。
- `newId` 为新 `id`，注意 `id` 不能与其他元素重复。

## 4. `edit-text` 编辑某元素内部的文本

```
edit-text element [newTextContent]
```

- `element` 为要编辑元素的 `id`。
- `newTextContent` 为新的文本内容，可以为空，表示清空该元素的文本内容。

## 5. `delete` 删除某元素

```
delete element
```

- `element` 为要删除元素的 `id`。

## 显示类命令

## 6. `print-indent` 按缩进格式显示

```
print-indent [indent]
```

- `indent` 为可选参数，表示每级缩进的空格数，默认为 2。当提供 `indent` 时，使用指定的空格数进行缩进显示。

## 7. `print-tree` 按树型格式显示

```
print-tree
```

## 8. spell-check 显示拼写检查结果

```
spell-check
```

- 调用拼写检查服务，显示拼写检查结果。检查结果的格式自定，合理即可。
- 需要能够检查 HTML 中的**所有 text 内容**。

## 输入/输出命令

提示：**编辑器必须先进行 read 或 init 命令，才可以使用其他命令。**

## 9. read 读入 HTML 文件

```
read filepath
```

- filepath 为读取文件的路径名。
- 进行必要的异常检测，例如读取的文件不存在。

## 10. save 写入 HTML 文件

```
save filepath
```

- filepath 为写入文件的路径名。
- 进行必要的异常检测，例如提供的路径名无法写入文件。

## 11. 初始化编辑器

```
init
```

- 将编辑器初始化为一个空的 HTML 模板供后续的编辑。
- 参考模板：

```
<html>
  <head>
    <title></title>
  </head>
  <body></body>
</html>
```

## 撤销和重做

支持多步撤销与多步重做，规则如下：

- 编辑类指令：支持撤销与重做。**如果在撤销后发生了编辑，则此时不允许重做操作。**
- 显示类指令：撤销与重做时应跳过显示类指令。
- 输入/输出指令：执行输入/输出指令后，不允许撤销与重做。

## 12. undo 撤销

```
undo
```

## 13. redo 重做

```
redo
```

## 评分方式

- 1. 架构设计：25 分  
    需要提供一个简单的文档，给出各个模块的描述以及依赖关系。可以补充一些关键的设计决策的说明。
- 2. 自动测试：25 分  
    针对各个模块完成自动测试代码。
- 3. 功能正确：40 分

功能	分值
insert	3
append	3
delete	3
edit-text	2
edit-id	2
undo	5
redo	5
read	3
save	3
init	1
print-indent	3
print-tree	3
spell-check	4

- 4. 代码结构：10 分  
    代码结构清晰，模块化，可读性强。

## 提交：

每人单独完成，3 周后提交

提交内容为一份压缩包，以学号\_姓名的格式命名，内容包括：

- 运行所需要的必要的代码文件
  - 包含所有你自己写的代码
  - 如果是通过包管理工具下载的第三方库，不需要提交。只需要提交依赖说明文件（如果有的话），例如 java 的 pom.xml 或者 js 的 package.json 等。
- 一份架构设计文档
  - 需额外在文档中说明如何运行你的编辑器程序，例如指明使用的语言及版本、安装依赖的步骤等。